



ΕΛΛΗΝΙΚΗ ΔΗΜΟΚΡΑΤΙΑ
Εθνικόν και Καποδιστριακόν
Πανεπιστήμιον Αθηνών
—ΙΔΡΥΘΕΝ ΤΟ 1837—


ΕΛΛΗΝΙΚΗ ΔΗΜΟΚΡΑΤΙΑ
Εθνικό και Καποδιστριακό
Πανεπιστήμιο Αθηνών

ΣΧΟΛΗ ΘΕΤΙΚΩΝ ΕΠΙΣΤΗΜΩΝ
ΤΜΗΜΑ ΒΙΟΛΟΓΙΑΣ

ΠΡΟΓΡΑΜΜΑ ΜΕΤΑΠΤΥΧΙΑΚΩΝ ΣΠΟΥΔΩΝ
«ΒΙΟΠΛΗΡΟΦΟΡΙΚΗ-ΥΠΟΛΟΓΙΣΤΙΚΗ ΒΙΟΛΟΓΙΑ»

Δημιουργία προγνωστικού αλγόριθμου με profile HMM

Μάθημα: Υπολογιστική Ανάλυση Αλληλουχιών Βιομακρομορίων



Απόστολος Π. Φυσεκίδης

Τμήμα Ψηφιακών Συστημάτων, Πανεπιστήμιο Πειραιώς

Α Θ Η Ν Α 2 0 2 5

Εισαγωγή:

Τα Profile Hidden Markov Models αντιπροσωπεύουν μια εξελιγμένη στατιστική προσέγγιση για την αναγνώριση και ανάλυση μοτίβων σε βιολογικές αλληλουχίες. Αυτά τα μοντέλα εστιάζουν κυρίως στις περιοχές που είναι διατηρημένες κατά την εξέλιξη, αξιοποιώντας την εξελικτική πληροφορία που είναι κωδικοποιημένη στις ομόλογες αλληλουχίες. Η θεωρητική τους βάση βασίζεται στην αρχή ότι οι λειτουργικά σημαντικές περιοχές των πρωτεϊνών τείνουν να διατηρούνται περισσότερο από τις μη λειτουργικές κατά τη διάρκεια της εξέλιξης.

Η δομή ενός Profile HMM περιλαμβάνει τρεις βασικές καταστάσεις που περιγράφουν διαφορετικές πτυχές της αλληλουχικής πληροφορίας. Η κατάσταση Match (M) αντιστοιχεί στη στοίχιση με διατηρημένα αμινοξέα, αντικατοπτρίζοντας θέσεις υψηλής εξελικτικής σημασίας. Η κατάσταση Insert (I) μοντελοποιεί την εισαγωγή αμινοξέων που δεν υπάρχουν στο κύριο μοτίβο, επιτρέποντας την προσαρμογή σε φυσικές παραλλαγές της αλληλουχίας. Η κατάσταση Delete (D) αναπαριστά την παράλειψη θέσεων από την αλληλουχία, καλύπτοντας τις περιπτώσεις ελλείψεων.

Η εκπαίδευση ενός Profile HMM βασίζεται σε πολλαπλή στοίχιση αλληλουχιών (MSA), η οποία παρέχει την απαραίτητη στατιστική πληροφορία για την εκτίμηση των παραμέτρων του μοντέλου. Αυτή η στοίχιση αντικατοπτρίζει τις πιθανότητες μετάβασης μεταξύ των διαφορετικών καταστάσεων και την πιθανότητα εκπομπής συγκεκριμένων αμινοξέων από κάθε θέση. Η στατιστική μοντελοποίηση επιτρέπει στο σύστημα να αποτυπώνει τόσο τη διατήρηση όσο και τη φυσική παραλλακτικότητα που παρατηρείται σε οικογένειες πρωτεϊνών.

Μεθοδολογία:

Η διαδικασία συλλογής δεδομένων ξεκίνησε με την εξαγωγή περίπου 1.450 κριτικά ανασκοπημένων πρωτεϊνών single-pass type I από τη βάση δεδομένων UniProt. Η επιλογή αυτή βασίστηκε σε κριτήρια ποιότητας, χρησιμοποιώντας συγκεκριμένα φίλτρα, όπως τις λέξεις-κλειδιά "transmembrane" για την αναγνώριση διαμεμβρανικών πρωτεϊνών, την υποκυτταρική τοποθεσία "single-pass type I" για τον προσδιορισμό του συγκεκριμένου τύπου, και το κριτήριο "reviewed: yes" για την εξασφάλιση της ποιότητας των σχολιασμών.


Για την αντιμετώπιση του προβλήματος της πλεονάζουσας πληροφορίας στο σύνολο δεδομένων, εφαρμόστηκε το εργαλείο CD-HIT με όριο ομοιότητας 40%. Αυτή η διαδικασία είχε ως στόχο την απομάκρυνση αλληλουχιών με υψηλή ομοιότητα, διατηρώντας μόνο μοναδικές αλληλουχίες που θα συνεισφέρον σημαντικά στην εκπαίδευση του μοντέλου.

Η στοίχιση πολλαπλών αλληλουχιών πραγματοποιήθηκε με τη χρήση του Clustal Omega. Αρχικά, χρησιμοποιήθηκαν οι πλήρεις αλληλουχίες των πρωτεϊνών για τη δημιουργία του συνολικού alignment που να περιλαμβάνει όλες τις δομικές περιοχές. Στη συνέχεια, εφαρμόστηκε μια πιο εστιασμένη προσέγγιση που περιλάμβανε μόνο τα τμήματα των transmembrane περιοχών, αναγνωρίζοντας ότι αυτές οι περιοχές ενδέχεται να περιέχουν τα πιο διακριτά χαρακτηριστικά για την ταξινόμηση.

Η κατασκευή του αρχικού Profile HMM πραγματοποιήθηκε με το εργαλείο hmmbuild του πακέτου HMMER, το οποίο αποτελεί το πρότυπο λογισμικό για τη δημιουργία και αξιολόγηση Hidden Markov Models σε βιολογικές αλληλουχίες. Το μοντέλο βασίστηκε στην πολλαπλή στοίχιση που είχε δημιουργηθεί προηγουμένως, εκμεταλλευόμενο τη στατιστική πληροφορία που περιέχεται στις διατηρημένες θέσεις και τα μοτίβα παραλλακτικότητας. Η διαδικασία αυτή παράγει ένα στοχαστικό μοντέλο που μπορεί να υπολογίζει την πιθανότητα μιας αλληλουχίας να ανήκει στην οικογένεια των διαμεμβρανικών πρωτεϊνών τύπου I.

Για την αντικειμενική αξιολόγηση της απόδοσης του μοντέλου, σχεδιάστηκε μια ολοκληρωμένη διαδικασία δοκιμής που περιλάμβανε τόσο θετικά όσο και αρνητικά σύνολα ελέγχου. Το θετικό σύνολο αποτελούνταν από 10 πρωτεΐνες τύπου I που δεν είχαν χρησιμοποιηθεί κατά τη φάση εκπαίδευσης του μοντέλου, εξασφαλίζοντας έτσι μια αμερόληπτη εκτίμηση της ικανότητας γενίκευσης. Αυτή η προσέγγιση ανεξάρτητου συνόλου δοκιμής είναι κρίσιμη για την αποφυγή της υπερ-προσαρμογής και την αξιόπιστη εκτίμηση της πραγματικής απόδοσης του μοντέλου.

Τα αρνητικά σύνολα δοκιμής σχεδιάστηκαν για να καλύπτουν διαφορετικές κατηγορίες πρωτεϊνών που θα μπορούσαν να συγχέονται με τις πρωτεΐνες-στόχους. Συγκεκριμένα, περιλάμβαναν 10 G-protein coupled receptors (GPCRs), οι οποίοι αντιπροσωπεύουν μια άλλη σημαντική κλάση διαμεμβρανικών πρωτεϊνών με διαφορετική τοπολογία. Επιπλέον, συμπεριλήφθηκαν 10 πρωτεΐνες τύπου II, που μοιράζονται κάποια δομικά χαρακτηριστικά αλλά διαφέρουν στον τρόπο εισόδου στη μεμβράνη. Τέλος, 10 σφαιρικές (globular) πρωτεΐνες χρησιμοποιήθηκαν ως αντιπρόσωποι πρωτεϊνών χωρίς διαμεμβρανικές περιοχές. Αυτή η ποικιλομορφία στα αρνητικά σύνολα επιτρέπει μια πολυδιάστατη αξιολόγηση της ειδικότητας του μοντέλου.




Αποτελέσματα:

Η αξιολόγηση του αρχικού Profile HMM μοντέλου αποκάλυψε μια μικτή εικόνα απόδοσης με συγκεκριμένα πλεονεκτήματα και περιορισμούς. Το μοντέλο επέδειξε άριστη ευαισθησία (sensitivity) με τιμή 1.0, γεγονός που σημαίνει ότι εντόπισε σωστά όλα τα θετικά παραδείγματα χωρίς κανένα ψευδώς αρνητικό αποτέλεσμα. Αυτή η επίδοση είναι ιδιαίτερα ενθαρρυντική καθώς καταδεικνύει ότι το μοντέλο κατάφερε να αποτυπώσει επιτυχώς τα χαρακτηριστικά που διακρίνουν τις διαμεμβρανικές πρωτεΐνες τύπου I και μπορεί να τις αναγνωρίζει αξιόπιστα όταν υπάρχουν στο σύνολο δεδομένων.

Ωστόσο, η ειδικότητα (specificity) του μοντέλου παρουσίασε σημαντικές ελλείψεις με τιμή 0.48, υποδεικνύοντας ότι το μοντέλο παρήγαγε έναν σημαντικό αριθμό ψευδώς θετικών αποτελεσμάτων. Αυτό το πρόβλημα εκδηλώθηκε κυρίως στην αναγνώριση των GPCRs, των πρωτεϊνών τύπου II και των σφαιρικών πρωτεϊνών ως διαμεμβρανικές πρωτεΐνες τύπου I. Η χαμηλή ειδικότητα αποτελεί σημαντικό περιορισμό για πρακτικές εφαρμογές, καθώς οδηγεί σε λανθασμένες ταξινομήσεις που θα μπορούσαν να παραπλανήσουν περαιτέρω ερευνητικές προσπάθειες. Αυτά τα αποτελέσματα υποδηλώνουν ότι το αρχικό μοντέλο, ενώ ήταν ικανό να εντοπίζει τα χαρακτηριστικά των πρωτεϊνών-στόχων, δεν είχε αναπτύξει επαρκή ικανότητα για να αποκλείει παρόμοιες αλλά διαφορετικές κατηγορίες πρωτεϊνών.


Μετρική	Τιμή
Ευαισθησία (TPR)	1.00
Ειδικότητα (TNR)	0.48
True Positives	9
False Positives	63
True Negatives	58
False Negatives	0



Η αναγνώριση των περιορισμών του αρχικού μοντέλου οδήγησε στην ανάπτυξη μιας βελτιωμένης προσέγγισης που εστίαζε αποκλειστικά στις transmembrane περιοχές των πρωτεϊνών. Αυτή η στρατηγική βασίστηκε στην υπόθεση ότι οι διαμεμβρανικές περιοχές περιέχουν τα πιο διακριτά χαρακτηριστικά για την ταξινόμηση και ότι η εστίαση σε αυτές θα μείωνε το θόρυβο από άλλες περιοχές της πρωτεΐνης. Η νέα προσέγγιση περιλάμβανε τη δημιουργία μιας συντομευμένης στοίχισης που περιείχε μόνο τα τμήματα που αντιστοιχούν στις διαμεμβρανικές περιοχές.


Το βελτιωμένο μοντέλο παρήγαγε σημαντικά διαφορετικά αποτελέσματα που έδειξαν μια πιο ισορροπημένη απόδοση. Η ευαισθησία μειώθηκε στο 0.778, αντιπροσωπεύοντας μια μικρή πτώση σε σχέση με το αρχικό μοντέλο. Αυτή η μείωση είναι αναμενόμενη καθώς η εστίαση σε περιορισμένες περιοχές μπορεί να οδηγήσει σε απώλεια κάποιας πληροφορίας που συνέβαλε στην αναγνώριση των θετικών παραδειγμάτων. Ωστόσο, η τιμή 0.778 εξακολουθεί να θεωρείται ικανοποιητική για πρακτικές εφαρμογές, καθώς σημαίνει ότι το μοντέλο εντοπίζει σωστά περίπου 4 στις 5 πραγματικές διαμεμβρανικές πρωτεΐνες τύπου I.

Μετρική	Τιμή
Ευαισθησία (TPR)	0.778
Ειδικότητα (TNR)	0.868
True Positives	7
False Positives	9
True Negatives	59
False Negatives	2



Η πιο εντυπωσιακή βελτίωση παρατηρήθηκε στην ειδικότητα, η οποία αυξήθηκε δραματικά στο 0.868. Αυτή η σημαντική βελτίωση υποδηλώνει ότι το βελτιωμένο μοντέλο κατάφερε να μειώσει

σημαντικά τον αριθμό των ψευδώς θετικών αποτελεσμάτων. Η υψηλή ειδικότητα σημαίνει ότι όταν το μοντέλο κατατάσσει μια πρωτεΐνη ως διαμεμβρανική τύπου I, υπάρχει υψηλή πιθανότητα αυτή η ταξινόμηση να είναι σωστή. Αυτό αποτελεί κρίσιμη βελτίωση για πρακτικές εφαρμογές, καθώς μειώνει τον κίνδυνο παραπλανητικών αποτελεσμάτων και αυξάνει την εμπιστοσύνη των ερευνητών στις προβλέψεις του μοντέλου.



Η εξέλιξη από το αρχικό μοντέλο με υψηλή ευαισθησία αλλά χαμηλή ειδικότητα στο βελτιωμένο μοντέλο με ισορροπημένη απόδοση αντικατοπτρίζει μια θεμελιώδη αρχή στη μηχανική μάθηση: την ανάγκη για ισορροπία μεταξύ της ικανότητας ανίχνευσης και της ακρίβειας ταξινόμησης. Το αρχικό μοντέλο, ενώ ήταν εξαιρετικά αποτελεσματικό στην αναγνώριση των πρωτεϊνών-στόχων, υπέφερε από υπερ-γενίκευση που οδηγούσε σε ψευδείς θετικές ταξινομήσεις.

Η επιτυχής μείωση των ψευδώς θετικών αποτελεσμάτων μέσω της εστίασης στις διαμεμβρανικές περιοχές υπογραμμίζει τη σημασία της βιολογικής γνώσης στον σχεδιασμό υπολογιστικών εργαλείων. Αυτή η προσέγγιση αναγνωρίζει ότι οι διαμεμβρανικές περιοχές περιέχουν τα πιο διακριτικά χαρακτηριστικά για την ταξινόμηση, καθώς αντιπροσωπεύουν τη λειτουργικά κρίσιμη περιοχή που διακρίνει αυτές τις πρωτεΐνες από άλλες κατηγορίες.

Βιβλιογραφία:

- Eddy, S. R. (1998). Profile hidden Markov models. *Bioinformatics*, 14(9), 755–763.
- Durbin, R., Eddy, S. R., Krogh, A., & Mitchison, G. (1998). *Biological sequence analysis: Probabilistic models of proteins and nucleic acids*. Cambridge University Press.
- Alberts, B., Johnson, A., Lewis, J., Morgan, D., Raff, M., Roberts, K., & Walter, P. (2014). *Molecular biology of the cell* (6th ed.). Garland Science.
- UniProt Consortium. (2021). UniProt: The universal protein knowledgebase in 2021. *Nucleic Acids Research*, 49(D1), D480–D489.

